나의 디지털 트윈 — 6년치 행동 데이터로 만드는 첫 prototype

AI 시대, 나만의 특수성·능력을 함께 고민하는 시스템

- 발표자: 20200572 엄상호
- 빅데이터컴퓨팅 기말 프로젝트 · 5-min talk
- "내 6년치 행동 데이터 위에서 7개 도구를 LLM이 취사선택해 호출하는 구조"

발표 구성 — 투 트랙 회고 + 3 이유

- 원래 **두 트랙**으로 준비했었습니다
- 트랙 A: 한국 와인 시장 mark-up + MAB (Wine21 **970개** + 관세청 **r=-0.752** 정량화 완료)
- 트랙 B: **6년치 개인 행동 데이터 + LLM 오케스트레이터** ← 오늘 발표
- 피벗 3 이유 (압축):
  - **데이터 진정성** — N=1이지만 실재 변동성, 발표자가 직접 검증 가능
  - **강의 §1~§4 → 7 도구 1:1 매핑** — 와인은 MAB 단일 알고리즘에 머뭄
  - **AI 시대 동기 정합** — 취업·진로 앞 나만의 특수성을 함께 고민할 디지털 트윈

[필수항목 1] 이전 연구 차용 / 본 기말프로젝트 신규

차용한 것

- 본인 사전 작업: wine-mab `src/mab/` UCB1 numpy 직접 구현 (T7로 흡수), `src/data/load.py`, ADR-001~009
- 강의 자료: `scipy.stats` / `numpy` / `sklearn.LinearRegression` 1줄 / `matplotlib`
- 외부: Apple Health export 포맷 / Google Timeline JSON 포맷 / Anthropic SDK

본 기말프로젝트로 새로 한 것

- `src/personal/` 패키지 신설 — data loader + **T1~T7** DS-tools + LLM orchestrator
- 7개 도구의 Anthropic `input_schema` wrap (강의 §1~§4 → LLM 호출 가능 표준 형태)
- LLM 오케스트레이터 (Anthropic `tool_use` loop + system prompt 4 rules + 환각 정규식 가드)
- Hero S1 부상 감지 시나리오 + 6 figure + DECK_PLAN/SLIDES/REPORT + ADR-

[필수항목 2] 데이터 수집 + raw data 정제

수집

- 5 sources: Apple Health `export.xml` (**216 MB**, 6년치) · Google Timeline JSON · iOS Headphone dB · GPX workout routes · workout meta
- Apple Health 건강앱 → 프로필 → '건강 데이터 내보내기' / Google Takeout JSON

정제 5단계

- (1) **XML 스트리밍 파싱** `xml.etree.ElementTree.iterparse` + `elem.clear()` → 메모리 **50 MB 이내**로 216 MB 처리
- (2) 일별 **8 metric** aggregate (steps/walking_speed/step_length/asymmetry/double_support/audio_db)
- (3) **timezone-aware** datetime + 좌표 → country bounding box 분류 (좌표 미저장)
- (4) `sourceName` 필터 — iPhone vs Nike Run Club **중복 stepCount 차단**

내가 세운 질문 + 방법론 7기법 매핑

Research Question

> 내 6년치 행동 데이터에서, *언제 무엇을 알려줄지*를 LLM이 7개 도구를 상황에 맞게 취사선택해 결정할 수 있는가? 단일 도구보다 정직하게 더 적은 false positive로 나오는가?

7 도구 매핑 (강의 §1~§4 → callable tool)

강의 기법	도구
§3.1 Welch t-test	**T2**
§3.2 Pearson r	**T1, T3**
§3.3 ANOVA	**T4**
§3.6 OLS / 이상치	**T5/T6**
§4 numpy K-means	**T6**

발견 1: V-curve "양은 늦게, 질은 먼저" (Pearson r=+0.638)

- 보행 속도와 시간 회복 추세 **Pearson r=+0.638** (p<1e-6)
- **2022 dip → 2023-06 cross** (회복 시점)
- "걸음 **양**은 줄어든 채로 있었지만, **질**은 이미 회복"
- 시사: 합계 metric만 보면 놓치는 패턴 → 다축 도구 필요

발견 2: 장소 효과 Paris vs Seoul (Welch d=+0.43)

- Paris **9,252** vs Seoul **6,890** steps/day (계절 매칭)
- Welch **t=3.94, p<0.001, Cohen's d=+0.43**
- "같은 사람도 환경이 다르면 행동이 다르다"
- 시사: 시간 trend만이 아니라 **장소 conditioning**이 행동을 흔든다

Hero — LLM 오케스트레이션 + 부상 감지 시나리오

- 7개 발견을 각각 **호출 가능한 도구**로 wrap
- `gym_A` 나오는 순간 → **T1+T2+T3+T7** 병렬 호출
- LLM 합성:

  > "헬스장 A에서 막 나오셨네요. 평소 60%까지 활동 떨어졌고(**d=-1.12**), 한쪽 다리 덜 쓰는 보행(**+1.7σ**) 보입니다. 무릎 어떠세요?"

- 핵심: 단일 도구로는 **false positive** — 도구 조합(T1·T2·T3·T7 cross-confirm)이 차단

Vision — 디지털 트윈 + 함께 만들 분

- AI 시대 본격 진입 + 취업 시기 → **나만의 특수성·능력** 고민 압축
- 오늘 보여드린 7개 도구 + LLM 오케스트레이터는 **그 고민을 함께 해 줄 디지털 트윈의 첫 부팅 단계**
- 다음 단계: 6년치 데이터 위에서 천천히 자라나서 **내가 모르는 내 패턴을 먼저 짚어 주는 비서**로
- **Call to action**: 여러분도 자기 데이터로 한번 시도해 보세요 — **5 source · 7 tool · 1 LLM** 이면 시작됩니다
- 학교 프로젝트 너머에서 이 디지털 트윈 취지에 공감하신다면, **함께 프로젝트 해 봅시다**

한계 + Q&A 안내

- **N=1** (일반화 금지) / sensor 결손 / **city-level only** (서울·파리·강원 북부) / LLM hallucination 정규식 가드
- 정직한 실패: **CUSUM recall 43%** / Paris 19h 가설 refuted / MAB chapter-level infeasible (알림 선택으로 흡수)
- 감사합니다 — **질문 환영합니다**